

Unidade Curricular de Métodos de Previsão Aplicados

Mestrado em Análise de Dados e Sistemas de Apoio à Decisão

Ano Letivo 2025-2026



“Previsão de Consultas na Região Centro: Uma Análise Comparativa entre Modelos Estatísticos e de Machine Learning em Diferentes Cenários Temporais”

Estudo Elaborado a 23 de março de 2026

Autores:

Afonso Bragança Gonçalves Azenha nº: a2025121150

Sara Henriques Simões nº: a2025103116

Índice

Índice de Tabelas	ii
Índice de Figuras.....	iii
Lista de siglas e acrónimos.....	iv
Introdução	1
2. Análise Exploratória de Dados	2
2.1. Tratamento e Limpeza.....	2
2.1.1. Estruturação Temporal e Tratamento de Zeros.....	2
2.1.2. Média Móvel e Variáveis de Calendário	2
2.2. Análise de Dependência Temporal.....	3
2.2.1. Autocorrelação (ACF) e Autocorrelação Parcial (PACF)	3
2.2.2. Decomposição Sazonal	4
3. Metodologia.....	5
3.1. Estratégia experimental para comparação.....	5
3.1.1. Seleção de Modelos e Algoritmos	5
3.2. Métricas de avaliação da capacidade preditiva	6
3.3. Preparação dos dados.....	6
4. Resultados e discussão	7
4.1. Análise Comparativa de Desempenho (Métricas Globais).....	7
5. Exemplificação das previsões objetivo	10
5.1. Método de previsão selecionado	10
5.2. Retreino do modelo e diagnóstico dos resíduos.....	11
Semana 1 - 29 de dezembro de 2025 a 4 de janeiro de 2026	11
Semana 2 — 12 de janeiro de 2026 a 18 de janeiro de 2026	12
Conclusão	15
Bibliografia	16

Índice de Tabelas

Tabela 1 - Métricas de Avaliação (Cenário 1)	8
Tabela 2 - Métricas de Avaliação (Cenário 2)	9
Tabela 3 - Métricas de Avaliação (Cenário 3)	10
Tabela 4 - Previsões pontuais e intervalares para a Semana 1 (29 dez. 2025 – 4 jan. 2026).....	14
Tabela 5 - Previsões pontuais e intervalares para a Semana 2 (12 jan. 2026 – 18 jan. 2026).....	14

Índice de Figuras

Figura 1 - Gráfico de Média Móvel.....	2
Figura 2 - Distribuição do número de consultas por dia da semana	3
Figura 3 - Função de Autocorrelação (ACF)	3
Figura 4 - Função de Autocorrelação Parcial (PACF).....	4
Figura 5 - Decomposição multiplicativa da série temporal: Tendência e Sazonalidade.....	4
Figura 6 - Função ACF dos resíduos do modelo final Semana 1	12
Figura 7 - Histograma dos resíduos do modelo final Semana 1	12
Figura 8 - Histograma dos resíduos do modelo final Semana 2	13
Figura 9 - Função ACF dos resíduos do modelo final Semana 2	13

Lista de siglas e acrónimos

ML: *Machine Learning*

RMSE: *Root Mean Squared Error*

MAE: *Mean Absolute Error*

MAPE: *Mean Absolute Percentage Error*

CSP: *Cuidados de Saúde Primários*

PACF: *Partial Autocorrelation Function*

ACF: *Autocorrelation Function*

PACF: *Parcial Autocorrelation Function*

Introdução

A gestão eficiente e a alocação de recursos nos Cuidados de Saúde Primários (CSP) representam um desafio constante, particularmente durante a época gripal, período caracterizado por picos de afluência e elevada pressão sobre o sistema de saúde. Neste contexto, a capacidade de antecipar a procura de consultas por síndrome gripal assume um papel crítico no planeamento estratégico.

O presente trabalho tem como objetivo central avaliar e comparar o desempenho preditivo de diversas metodologias de previsão de séries temporais. Pretende-se projetar o número diário de consultas por síndrome gripal nos CSP, focando a previsão num horizonte de sete dias consecutivos. Adicionalmente, de forma a simular as condições reais de operação e o atraso inerente à notificação e consolidação dos dados de saúde, as projeções assumem um hiato de três dias, correspondendo assim a um horizonte de previsão focado entre os dias 4 e 10. A modelação foi desenvolvida com recurso à linguagem *Python* e ao ecossistema de bibliotecas *Nixtla*, partindo de uma abordagem baseada em modelos estatísticos clássicos até à exploração de algoritmos de aprendizagem automática *Machine Learning*.

2. Análise Exploratória de Dados

2.1. Tratamento e Limpeza

2.1.1. Estruturação Temporal e Tratamento de Zeros

A fiabilidade de qualquer modelo de previsão está intrinsecamente dependente da qualidade da série temporal subjacente. Após a extração dos dados referentes à época gripal da região Centro, estruturou-se o *DataFrame* para garantir que o índice temporal assumia o formato datetime adequado, forçando-se a série a uma frequência diária constante. A análise descritiva confirmou a integridade da extração, não se verificando qualquer omissão temporal, *missing values*. Ainda assim, para blindar o *pipeline* face a futuras extrações, implementou-se preventivamente um método de imputação por interpolação linear.

Durante a inspeção aos dados, identificou-se a presença de dias com zero consultas registadas. Importa salientar que estes zeros representam dias sem afluência ou com os serviços encerrados, e não falhas de registo. Contudo, como a presença de valores nulos inviabiliza matematicamente a aplicação de algoritmos de decomposição multiplicativa, procedeu-se à adição de uma constante unitária (+1) à série durante os testes de decomposição, prevenindo erros de divisão e assegurando a continuidade das análises.

2.1.2. Média Móvel e Variáveis de Calendário

Para atenuar a forte componente sazonal Intra semanal nomeadamente as quebras sistemáticas de afluência aos fins de semana e isolar a tendência subjacente, calculou-se uma média móvel com uma janela de 7 dias. O gráfico resultante (Figura 1) evidencia claramente a curva crescente das consultas ao longo dos meses de inverno, confirmando a não-estacionariedade da série.




Figura 1 - Gráfico de Média Móvel

No âmbito da preparação das variáveis auxiliares, construiu-se um calendário de dias não úteis. Este calendário integra feriados nacionais, fins de semana e um conjunto de datas identificadas manualmente, como greves e tolerâncias de ponto que afetaram o setor da saúde.

Com base neste mapeamento, criaram-se duas variáveis preditivas: `nao_util`, variável binária que assume o valor 1 em dias de interrupção ou redução de serviço e `dia_semana`, variável numérica de 0 a 6 para identificar o perfil de cada dia.

2.2. Análise de Dependência Temporal

A compreensão da dinâmica interna da série exigiu uma avaliação aprofundada das suas componentes estruturais. A análise visual preliminar, suportada pelos gráficos de dispersão distributiva agrupados por dia da semana (Figura 2), revelou um padrão comportamental muito vincado: um volume elevado e crescente de consultas durante os dias úteis, seguido de uma quebra abrupta aos fins de semana.




Figura 2 - Distribuição do número de consultas por dia da semana

2.2.1. Autocorrelação (ACF) e Autocorrelação Parcial (PACF)

Para validar estatisticamente esta observação empírica, recorreu-se ao estudo dos desfasamentos temporais. A Função de Autocorrelação revelou coeficientes que ultrapassam significativamente as bandas de confiança (a 95%) em desfasamentos múltiplos de sete, observáveis até ao *lag* 42 (Figura 3). Fica assim provada a existência de uma forte sazonalidade intra-semanal de período sete ($m=7$).




Figura 3 - Função de Autocorrelação (ACF)

A análise complementar através da Função de Autocorrelação Parcial (Figura 4) permitiu isolar o efeito direto de cada período. O *lag* 1 destacou-se como o mais expressivo, evidenciando forte persistência diária. O *lag* 7 manteve-se estatisticamente significativo, confirmando a sazonalidade semanal, acompanhado de uma correção negativa no *lag* 8 (característica típica dos processos sazonais autorregressivos). A partir do *lag* 9, os coeficientes entram nas bandas de confiança, provando que o histórico temporal mais relevante para a previsão se concentra nos sete dias anteriores.




Figura 4 - Função de Autocorrelação Parcial (PACF)

2.2.2. Decomposição Sazonal

Face à identificação desta sazonalidade e da evidente não-estacionariedade da série (marcada pela evolução da época gripal), procedeu-se à decomposição da série temporal, comparando as abordagens aditiva e multiplicativa.

A análise visual das componentes (Figura 5) permitiu concluir que a amplitude da sazonalidade aumenta proporcionalmente ao nível da tendência, ou seja, as flutuações de afluência são muito maiores no pico do inverno do que no início da época. Esta evidência matemática de variância não constante dita que a estrutura multiplicativa é a mais adequada para modelar a série, uma vez que o modelo aditivo falharia em capturar a verdadeira magnitude dos picos de incidência gripal. Adicionalmente, a análise ao correlograma dos resíduos gerados por este modelo confirmou um ajustamento superior, aproximando-se de forma muito mais satisfatória do conceito teórico de ruído branco.




Figura 5 - Decomposição multiplicativa da série temporal: Tendência e Sazonalidade

3. Metodologia

3.1. Estratégia experimental para comparação

A estratégia experimental foi elaborada de forma a permitir a comparação direta e justa entre diversos modelos de previsão, nomeadamente modelos elementares, estatísticos e de *Machine Learning*, tendo em consideração a quantidade de histórico disponível, uma variável crítica na previsão de fenómenos sazonais. Para tal, definiram-se três distintos cenários:

- Cenário 1: Dados a partir de 1 de julho de 2025 para testar a capacidade de previsão apenas com dados da época corrente;
- Cenário 2: Dados a partir de 1 de setembro de 2024, onde consta o histórico da época gripal anterior completa;
- Cenário 3: Dados a partir de 1 de setembro de 2023, permitindo ao modelo captar padrões de sazonalidade anual e tendências de longo prazo.

Todos os cenários terminaram com a extração dos dados a 31 de janeiro de 2026.

Após a definição dos cenários, de forma a evitar que o desempenho dos modelos fosse enviesado por um período específico, realizou-se a estratégia de Validação Cruzada com *Sliding Windows*, utilizando as bibliotecas *StatsForecast* e *MLForecast*, na linguagem *Python* e no *ecossistema Nixtla*. Este passo garante que a comparação entre modelos é justa e não dependente de um único dia de testes.

3.1.1. Seleção de Modelos e Algoritmos

A etapa de modelação preditiva iniciou-se após a escolha dos algoritmos a implementar:

- ***Seasonal Naive***: baseia-se no princípio da persistência sazonal ($m=7$), assumindo que a previsão para uma determinada observação futura será a mesma que a última observação registada no mesmo ponto do ciclo sazonal.
- ***AutoARIMA***: algoritmo que automatiza a procura e otimização dos parâmetros. Foi parametrizado com *seasonal_length* = 7 de modo a ajustar a componente autoregressiva e as médias móveis à dinâmica semanal das consultas. Foram ainda testadas duas versões deste algoritmo, uma versão Base e outra que considera as variáveis exógenas criadas.
- ***MSTL***: modelo de decomposição que isola a tendência e sazonalidade através de regressões locais, utilizando o método *Lowess*. Possibilita uma modelação mais flexível do padrão cíclico, e foi testada sem e com a consideração das variáveis exógenas.
- ***Modelos de Machine Learning (Random Forest e XGBoost)***: utilizados para entender e captar relações não-lineares. Estes exigem a criação de uma janela de atributos com lags sazonais ($m=7,14$) e variáveis exógenas para que o modelo consiga realizar as previsões com base na estrutura da série.

Para os modelos de *Machine Learning* (ML), a seleção dos hiperparâmetros necessários não foi efetuada de forma manual, optou-se por aplicar a técnica *Grid Search* integrada na validação cruzada. Para isso, construiu-se uma grelha de possíveis valores para os parâmetros dos algoritmos a serem testados.

No caso do *Random Forest*, testaram-se diversas profundidades (*max_depth*), desde 5, 10 ou ilimitada e o número de árvores no modelo (*n_estimators*) de 100 ou 200.

Quanto ao *XGBoost*, o foco permaneceu na taxa de aprendizagem (*learning_rate*) de 0.05 e 0.1 que controla a velocidade e a precisão com que o algoritmo corrige os erros das iterações anteriores

Após esta escolha, o *Grid Search* executou todas as combinações possíveis dentro das janelas de validação cruzada, sendo o modelo final selecionado para cada modelo aquele que apresentou o menor erro médio no conjunto de testes. Esta escolha garantiu que a comparação entre ML e os modelos estatísticos fosse feita utilizando a melhor configuração possível.

3.2. Métricas de avaliação da capacidade preditiva

Para que se possa determinar qual o modelo que melhor prevê o número de consultas durante as semanas selecionadas, é essencial a escolha de métricas de avaliação oportunas:

O *Mean Absolute Error* (MAE) é uma das métricas mais relevantes deste estudo, devido à facilidade de interpretação. Calcula a média das diferenças absolutas entre os valores reais e as previsões, expressando o erro na mesma unidade dos dados originais (número de consultas). Neste contexto, torna-se mais intuitivo e simples, pois poderá afirmar-se que o modelo tem um erro médio de “X consultas por dia”.

Selecionou-se também o *Root Mean Square Error* (RMSE) que mede a magnitude do erro, no entanto atribui um peso superior aos erros de maior dimensão, pois as diferenças são elevadas ao quadrado antes de ser extraída a raiz média. Na prática, o RMSE permite identificar e penalizar modelos que demonstram estes *outliers* de erro, garantindo uma maior segurança na previsão de picos de procura, pois um erro muito grande num único dia é mais prejudicial do que vários erros pequenos.

Por fim, optou-se por avaliar também o *Mean Absolute Percentage Error* (MAPE). Utilizado como indicador complementar, esta métrica fornece a precisão do modelo em termos percentuais, calculando a média das percentagens de erro face aos valores reais. A sua escolha deve-se à capacidade do MAPE de comparar o desempenho do modelo em diferentes períodos da série, dado que permite entender se o erro de 20 consultas representa uma falha grave ou um erro residual.

A seleção final do melhor modelo será feita de acordo com estas métricas, e irá privilegiar o que apresentar o menor MAE, dado que este minimiza o erro médio diário. O RMSE é utilizado como critério de desempate para garantir estabilidade perante grandes variações.

3.3. Preparação dos dados

Esta fase é fundamental, uma vez que a qualidade das previsões depende diretamente da forma como os dados foram expostos aos modelos selecionados. Durante esta fase, os dados foram transformados para o formato exigido pelas bibliotecas da *Nixtla* (*ds*, *y*, *unique_id*) e foi verificada a presença de valores omissos de modo a garantir a continuidade da série temporal.

Nos modelos de *Machine Learning* foi necessária uma etapa de engenharia de atributos para que se pudesse converter a série temporal num problema de aprendizagem supervisionada:

- **Lags:** Foram gerados *lags* de 7 e 14 dias. Esta escolha permite que o modelo identifique a forte sazonalidade semanal da série;
- **Variáveis exógenas:** Integraram-se duas variáveis essenciais para encontrar entender padrões de operação. A “*nao_util*” é uma variável binária que identifica os dias de interrupção ou redução de serviço (fins de semana, feriados nacionais, tolerâncias de ponto, greves) que afetaram o setor onde a afliência desce, assumindo o valor 1 nestes dias e 0 nos restantes. A “*dia_semana*” é uma variável numérica (0 a 6) que permite ao modelo identificar o dia e aprender o perfil específico de cada dia da semana.

Estas variáveis exógenas foram disponibilizadas tanto no conjunto de treino como no horizonte de previsão, de forma a garantir que todos os modelos estivessem em igual circunstância e estivessem na posse deste conhecimento antecipadamente sobre a natureza dos dias a prever.

Para a avaliação do desempenho de todos os modelos, foi essencial definir vários parâmetros para se proceder a validação cruzada.

Relativamente ao número de janelas, utilizaram-se 14 no Cenário 1 e 7 no Cenário 2 e 3. Esta escolha baseou-se na sazonalidade semanal ($m=7$) identificada durante a Análise Exploratória de Dados, uma vez que ao utilizar-se múltiplos do período sazonal, garante-se que todos os dias da semana (úteis e fins de semana) têm exatamente o mesmo peso no cálculo das métricas agregadas, evitando deturpações durante a avaliação da performance dos modelos.

O *step_size* definido foi de 1 para simular o comportamento real de uma unidade de saúde, dado que as previsões são atualizadas diariamente à medida que novos dados são carregados no sistema.

Adicionalmente, considerou-se um horizonte temporal de 10 dias. Esta escolha baseia-se no facto da existência de um hiato de 3 dias no reporte dos dados no sistema. Assim, para que fosse possível prever os 7 dias de alvo pretendidos, o horizonte temporal teria de refletir a soma entre o hiato e os dias de alvo.

Embora o objetivo fosse a previsão focada nos horizontes $h = 4$ a $h = 10$, os restantes horizontes não foram omitidos do trabalho, o que permitiu confirmar visualmente que os modelos iniciam a sua previsão de forma coerente. Não obstante, é de referir que as métricas apresentadas no capítulo seguinte refletem o erro médio acumulado relativo ao horizonte total e, por isso, inclui o período de hiato, garantindo-se uma comparação justa entre todos os cenários e modelos.

4. Resultados e discussão

4.1. Análise Comparativa de Desempenho (Métricas Globais)

A análise Comparativa de Desempenho seguiu as métricas MAE, RMSE e MAPE, calculadas após a execução da estratégia de validação cruzada, permitindo identificar a abordagem mais robusta para a previsão de consultas.

No primeiro cenário (dados desde julho de 2025), testou-se a resiliência dos modelos num contexto com escassez de dados históricos. Com apenas alguns meses de informação, os

modelos apresentaram dificuldade em distinguir ruído diário de tendência sazonal de longo prazo.

Neste cenário, o modelo vencedor foi o AutoARIMA_Exog, dado que apresenta as métricas mais reduzidas (Tabela 1). As variáveis exógenas demonstraram ser úteis para a aprendizagem do algoritmo, funcionando como uma mais-valia e uma informação para criar padrões. Como o modelo tinha poucas semanas para aprender, a indicação explícita destes dias permitiu-lhe ajustar a curva de imediato, algo que um modelo univariado demoraria mais tempo a entender apenas através dos dados. O modelo ARIMA conseguiu adaptar-se de forma rápida à inclinação da curva da época gripal do ano 2025/2026.

A análise conjunta das métricas possibilita obter conclusões importantes sobre a fiabilidade das previsões neste cenário. Primeiramente, a estabilidade do erro, quando se realiza a comparação entre o MAE e o RMSE. A proximidade entre estes valores indica robustez. Considerando que o RMSE penaliza desvios de grande magnitude, a diferença reduzida entre estas métricas sugere que o modelo não apresenta erros enormes.

Um MAPE de 73% neste cenário é expectável, uma vez que a ausência de histórico de anos anteriores dificulta a calibração das quedas abruptas de consultas nestes dias. Por isso, em séries temporais de saúde como esta, onde existe uma forte componente sazonal, os dias com menor afluência registam valores reais baixos e, nestes casos, um desvio absoluto residual resulta num erro percentual matematicamente elevado.

É de reparar que neste cenário os modelos de ML atingiram erros MAE de cerca de 120 consultas e RMSE de 130, o desempenho mais frágil do estudo. A necessidade de grandes volumes de dados para treinar estes modelos transformou-se num cenário de *underfitting*. Este resultado demonstra que em contextos com dados reduzidos, a estatística clássica assistida por variáveis exógenas oferece maior fiabilidade.

	MAE	RMSE	MAPE
AutoARIMA_Exog	48.22	57.98	0.73
AutoARIMA_Base	62.86	73.84	1.23

Tabela 1 - Métricas de Avaliação (Cenário 1)

No cenário 2, com a inclusão de um ciclo anual completo, a precisão dos algoritmos aumentou significativamente. Ter dados desde setembro de 2024 permitiu que os modelos fossem expostos à sazonalidade do inverno anterior, o que resultou na redução do MAE em 15% no modelo AutoARIMA_Exog.

Curiosamente, neste cenário, foi o modelo AutoARIMA_Base que apresentou menores erros, com um MAE de 40.49 (Tabela 2), uma redução de cerca de 36% em comparação com o cenário 1 (62.86 para 40.49). Este facto demonstra que o modelo ao ter acesso a mais meses de histórico é capaz de identificar os ciclos semanais de forma orgânica, tornando a ajuda das variáveis exógenas menos determinantes.

Note-se que a inclusão destes novos dados permitiu que o modelo conseguisse estabilizar a sua componente de tendência, tornando-o menos sensível a flutuações pontuais e mais atento à estrutura real do período gripal.

As métricas confirmam que os algoritmos se tornaram mais assertivos na previsão dos picos e a redução do valor do RMSE demonstra que os desvios de grande magnitude que aconteciam anteriormente devido à falta de contexto, foram significativamente mitigados.

Também o MAPE registou uma descida, provando que a disponibilização de um maior número de dados permite ao modelo calibrar as proporções de erro de melhor forma, mesmo em dias com menor afluência.

Neste cenário, os modelos ML demonstraram resultados significativamente melhores, no entanto ainda bastante acima dos valores dos modelos estatísticos. Este facto confirma o que anteriormente se concluiu e reforça a ideia de que a estatística clássica oferece maior fiabilidade neste contexto.

	MAE	RMSE	MAPE
AutoARIMA_Exog	41.13	52.12	0.55
AutoARIMA_Base	40.49	49.88	0.63
XGB_lr0.05	64.47	73.63	-
RF_d5_n200	73.05	82.96	-

Tabela 2 - Métricas de Avaliação (Cenário 2)

O cenário 3 demonstra ser o melhor deste estudo, utilizando o histórico mais extenso disponível (aproximadamente 10 trimestres). Estes dados permitiram aos modelos em análise captar tanto a sazonalidade semanal, como as nuances de transição entre as épocas gripais consideradas e tendências de longo prazo. Neste cenário, observou-se o valor do erro médio mais baixo de toda a experimentação no algoritmo AutoARIMA_Base de 36.81 (Tabela 3).

A abundância de dados confirmou o que já se suspeitava no cenário 2, e as variáveis exógenas não demonstraram ter um peso tão importante, visto que os modelos conseguiram perceber com precisão a estrutura da série através de informação estatística presente na série temporal e prever as quebras de fim de semana e a retoma de pressão à segunda-feira.

O RMSE sustenta este facto, apresentando também o valor mais reduzido de todos os modelos e cenários de 48.45.

Mesmo considerando o hiato de 3 dias, o AutoARIMA_Base revelou coerência ao longo da sua previsão, provando que com apoio na estabilidade dos padrões históricos de anos anteriores guardados na sua memória, o modelo consegue prever os períodos de ausência de dados.

Relativamente aos modelos ML, embora ambos tenham apresentado os melhores valores quando comparados com eles próprios em todos os cenários (com MAE a situar-se nos 43.94 e 49.60), ainda assim não conseguiram superar a eficácia dos modelos estatísticos, nomeadamente o ARIMA. Os modelos ML, apesar da otimização por *GridSearch*, revelaram uma tendência para reagir de forma exagerada a ruídos pontuais, o que penalizou o seu RMSE.

Em comparação com o cenário 2, o MAE apresenta uma melhoria de 9% no modelo AutoARIMA_Base (40.49 para 36.81).

	MAE	RMSE	MAPE
SeasonalNaive	57.63	66.28	1.12
MSTL_Base	49.98	63.96	0.68
MSTL_Exog	49.98	63.96	0.68
AutoARIMA_Base	36.81	48.45	0.58
AutoARIMA_Exog	37.84	50.86	0.53
AutoETS	46.50	59.94	0.73
XGB_lr0.05	43.94	61.38	1.34
RF_dNone_n200	49.60	58.23	1.23

Tabela 3 - Métricas de Avaliação (Cenário 3)

A análise comparativa dos três cenários possibilita a validação da hipótese inicial do estudo em questão, isto é, se a quantidade de dados é o fator crítico para a fiabilidade da previsão neste setor.

Observou-se uma trajetória de melhoria contínua de todas as métricas, representando uma redução total do MAE do cenário 1 para o 3 de cerca de 41%. Este ganho traduz-se, na prática, numa capacidade muito acima da unidade em prever o número de consultas.

Contrariamente à tendência dos dias de hoje, onde se privilegia modelos ML complexos, este estudo demonstra que, para séries temporais com sazonalidade semanal e elevada volatilidade, os modelos estatísticos como o AutoARIMA continuam a ser mais robustos e fiáveis.

Além disso, provou-se que as variáveis exógenas criadas são ferramentas com valor no curto prazo, mas tornam-se redundantes em contextos onde o histórico é suficientemente longo para que o modelo aprenda os padrões do calendário por si só.

5. Exemplificação das previsões objetivo

Após a avaliação comparativa dos modelos, importa agora materializar as previsões para as duas semanas em análise. Este processo de previsão final baseia-se exclusivamente no Cenário 3, que contém dados desde setembro de 2023, uma vez que a riqueza do seu histórico permitiu ao modelo selecionado atingir a sua precisão preditiva.

5.1. Método de previsão selecionado

A seleção do método de previsão final decorreu de uma avaliação transversal aos três cenários testados. No Cenário 1, caracterizado pela escassez de dados históricos, o modelo *AutoARIMA_Exog* obteve o melhor desempenho, evidenciando a importância das variáveis exógenas, como feriados e greves, para orientar o algoritmo quando o histórico é limitado.

Contudo, com o aumento da profundidade temporal nos Cenários 2 e 3, o modelo *AutoARIMA_Base* superou a concorrência, demonstrando que o próprio padrão da série temporal era suficiente para uma modelação robusta. A decisão final recaiu, assim, sobre a aplicação do *AutoARIMA_Base* treinado com os dados do Cenário 3, por ter sido a combinação que registou as melhores métricas de erro globais em toda a experiência, com um MAE de 36,81 e RMSE de 48,45 consultas.

O modelo foi retreinado de raiz para cada uma das duas semanas-alvo, sendo instanciado com os parâmetros *season_length=7*, para espelhar a sazonalidade intra-semanal, e *d=None*, permitindo que a ordem de integração fosse determinada automaticamente pelo modelo. Ao ajustar o algoritmo a toda a extensão do histórico disponível até ao corte imposto pelo hiato de três dias, assegurou-se a máxima precisão de cada previsão face à realidade mais recente.

5.2. Retreino do modelo e diagnóstico dos resíduos

A metodologia de retreino adotada reflete as condicionantes operacionais reais descritas no enunciado nomeadamente, como já referido, a existência de um hiato de três dias entre a data atual e a última observação disponível no sistema. Assim, para prever os sete dias do período-alvo, o modelo é treinado com todo o histórico disponível até três dias antes do início da semana pretendida. Em termos práticos, gera-se uma previsão para um horizonte total de dez dias, $h=10$. Embora o foco da análise seja os horizontes $h=4$ a $h=10$, as métricas de desempenho refletem o erro médio acumulado de todo o horizonte.

Semana 1 - 29 de dezembro de 2025 a 4 de janeiro de 2026

Para a Semana 1, o conjunto de treino foi definido com dados até 25 de dezembro de 2025 (inclusive), sendo a previsão lançada a partir de 26 de dezembro de 2025 para um horizonte de dez dias. Após o ajustamento do modelo ao conjunto de treino, procedeu-se à extração dos valores ajustados, *fitted values*, com o objetivo de calcular os resíduos, definidos como a diferença entre os valores observados e os valores ajustados pelo modelo, permitindo avaliar a qualidade do ajustamento do modelo antes de avançar para a previsão.

O gráfico temporal dos resíduos revelou uma distribuição aleatória em torno de zero, o que constitui um sinal favorável quanto à adequação do modelo.

A análise do correlograma ACF dos resíduos (Figura 6), calculado para 14 defasamentos, equivalentes a dois ciclos sazonais semanais, confirmou a ausência de autocorrelação estatisticamente significativa, na medida em que nenhum dos coeficientes ultrapassou as bandas de confiança a 95%.

Este resultado foi corroborado formalmente pelo teste de *Ljung-Box*, cujos *p-values* superiores a 0,05 em todos os defasamentos testados indicam que se aceita a hipótese nula do teste e confirma-se a ausência de autocorrelação nos resíduos. Destaca-se o valor de referência *lag 14*, por corresponder a dois ciclos sazonais semanais completos, que registou um *p-value* de 0,891., um valor robusto que atesta a eficácia do modelo em captar a dinâmica das consultas.

Por fim, o histograma dos resíduos (Figura 7) exibiu uma distribuição aproximadamente centrada em zero e com forma próxima de “sino”. Isto sugere uma distribuição próxima da normalidade, sem assimetrias ou valores extremos preocupantes.

O conjunto destes diagnósticos permite concluir que os resíduos se comportam como ruído branco e que o modelo foi adequadamente ajustado aos dados de treino validando a qualidade das previsões produzidas.




Figura 6 - Função ACF dos resíduos do modelo final
Semana 1




Figura 7 - Histograma dos resíduos do modelo final
Semana 1

Semana 2 — 12 de janeiro de 2026 a 18 de janeiro de 2026

Na Semana 2, o mesmo procedimento foi replicado de forma análoga. O conjunto de treino foi estendido até 8 de janeiro de 2026 (inclusive), e a previsão foi lançada a partir de 9 de janeiro de 2026 para um horizonte de dez dias. O modelo foi retreinado de raiz com este novo conjunto de treino, mais alargado, incorporando assim a evolução mais recente da série e tirando partido da maior quantidade de informação disponível.

A análise dos resíduos revelou desafios de modelação que não foram encontrados na primeira semana, apontando para uma maior volatilidade.

A inspeção visual do gráfico temporal dos resíduos revelou uma distribuição aparentemente aleatória em torno de zero. Este comportamento é um indicador de que o modelo foi capaz de captar a informação, sendo um sinal favorável à adequação do modelo AutoARIMA_base para as previsões.

Contudo, a análise do correlograma ACF dos resíduos (Figura 6) revelou coeficientes que ultrapassam as bandas de confiança de 95%, sugerindo que ainda existe autocorrelações não totalmente capturadas.

Este cenário foi corroborado pelo teste de *Ljung-Box*, onde o *p-value* de 1.978×10^{-8} (inferior a 5%) no *lag* 14 levou à rejeição da hipótese nula de ausência de autocorrelação.

Apesar disso, o histograma dos resíduos (Figura 7) mantém uma distribuição aproximadamente centrada em zero e com forma próxima de “sino”, indicando que o modelo não apresenta desvios graves, apenas alguma dificuldade em processar o ruído extremo deste período.

Este resultado pode ser explicado pela natureza desta semana, que coincide com o período de maior intensidade da época gripal. Ocorreu uma grande aceleração na procura de

consultas, o que introduz uma volatilidade estrutural que o modelo dificilmente consegue capturar na totalidade com base no histórico disponível.

caracterizado por uma aceleração abrupta da procura de consultas que introduz uma volatilidade estrutural que o modelo dificilmente consegue capturar na totalidade com base no histórico disponível.




Figura 9 - Função ACF dos resíduos do modelo final Semana 2




Figura 8 - Histograma dos resíduos do modelo final Semana 2

5.3. Previsão pontual e intervalar

As previsões foram obtidas com o parâmetro, $level=[80, 95]$, produzindo além da previsão pontual, os intervalos de previsão a 80% e a 95% de confiança, apresentados nas Tabelas 4 e 5 para a Semana 1 e Semana 2, respetivamente. Uma vez que a variável em estudo representa contagens físicas (número de consultas) todos os limites numéricos inferiores que resultaram em valores negativos foram limitados a zero, garantindo a total coerência prática dos dados.

Para a Semana 1, o modelo capturou com precisão a dinâmica atípica da quadra festiva. Refletiu uma quebra abrupta de afluência nos dias 31 de dezembro e 1 de janeiro, com estimativas de apenas 51 e 24 consultas, respetivamente. Contrasta fortemente com os restantes dias, cujos valores oscilam entre as 95 e as 282 consultas. Os intervalos de previsão são naturalmente mais amplos nos dias úteis, onde a procura é mais elevada e variável, e o intervalo a 95% para o dia 29 de dezembro chega a um máximo de 348 consultas.

Data	Previsão	Lo-95	Lo-80	Hi-80	Hi-95
2025-12-29	282	217	239	325	348
2025-12-30	254	175	202	306	333
2025-12-31	51	0	0	103	131
2026-01-01	24	0	0	77	106

2026-01-02	216	133	162	270	299
2026-01-03	141	57	86	196	226
2026-01-04	95	6	37	153	184

Tabela 4 - Previsões pontuais e intervalares para a Semana 1 (29 dez. 2025 – 4 jan. 2026)

Para a Semana 2, as previsões refletem um período de maior atividade gripal, com valores pontualmente mais elevados, variando entre 79 consultas ao sábado e 310 consultas à segunda-feira. O modelo mantém a sazonalidade semanal esperada, com os dias de fim de semana a registarem previsões substancialmente inferiores aos dias úteis. Em termos de incerteza, constata-se que os intervalos de previsão são consistentemente mais largos do que os da Semana 1. Este alargamento é estatístico e factualmente coerente, perante uma projecção de maior volume absoluto de casos, a variabilidade e a incerteza associadas aumentam na mesma proporção.

Data	Previsão	Lo-95	Lo-80	Hi-80	Hi-95
2026-01-12	310	240	264	357	381
2026-01-13	307	223	252	363	392
2026-01-14	270	185	214	325	355
2026-01-15	217	130	160	273	303
2026-01-16	186	98	128	244	274
2026-01-17	79	0	21	138	169
2026-01-18	99	8	40	158	189

Tabela 5 - Previsões pontuais e intervalares para a Semana 2 (12 jan. 2026 – 18 jan. 2026)

Conclusão

O presente trabalho permitiu concluir que o histórico de dados disponíveis para análise é um fator determinante na eficácia da previsão de consultas no CSP da região Centro.

Com maior escassez de dados, o *AutoARIMA_Exog* revelou-se o mais robusto, demonstrando que as variáveis exógenas são um complemento essencial quando o histórico é insuficiente para identificar padrões sazonais de forma autónoma. Contudo, com o aumento do histórico, o modelo *AutoARIMA_Base* superou progressivamente todos os concorrentes, provando que a abundância de dados possibilita a captura da estrutura sazonal de forma autónoma.

Destaca-se ainda que os modelos de ML, apesar do seu potencial, revelaram-se sistematicamente inferiores aos modelos estatísticos clássicos em todos os cenários, refletindo a sua dependência de volumes de dados muito mais massivos para conseguirem generalizar adequadamente.

A validação dos resultados provou a utilidade do modelo ARIMA, dado que na primeira semana o modelo captou de forma correta a quebra do período festivo e na segunda semana, o diagnóstico de resíduos e o teste *Ljung-Box* revelaram autocorrelação residual. Estes resultados refletem a dificuldade em processar a volatilidade do pico gripal de janeiro somente com base no histórico.

Como trabalho futuro, seria de enorme valor investigar a inclusão de variáveis exógenas específicas para estes períodos críticos tais como dados meteorológicos, alertas de vagas de frio, ou o efeito do regresso às atividades escolares e laborais, dotando o modelo de ferramentas extra para prever choques abruptos na procura de cuidados de saúde.

Bibliografia

- Leite, J. (2026). *Introdução à análise e previsão de séries temporais: Módulo 1 (v2.0)* [Diapositivos de apresentação]. Coimbra Business School - ISCAC.
- Leite, J. (2026). *Decomposição de séries temporais: Módulo 2 (v2.0)* [Diapositivos de apresentação]. Coimbra Business School - ISCAC.
- Leite, J. (2026). *Métodos de Previsão: Módulo 3 (v2.0)* [Diapositivos de apresentação]. Coimbra Business School - ISCAC.
- Leite, J. (2026). *Avaliação dos Métodos de Previsão: Módulo 4 (v2.0)* [Diapositivos de apresentação]. Coimbra Business School - ISCAC.
- Leite, J. (2026). *NB1-Parte1* [Jupyter Notebook]. Google Colaboratory.
[\[https://colab.research.google.com/drive/1T9qNbmYM4AEN1h1s4zbF7kuLVdV6UiHA?usp=drive_link\]](https://colab.research.google.com/drive/1T9qNbmYM4AEN1h1s4zbF7kuLVdV6UiHA?usp=drive_link)
- Leite, J. (2026). *NB1-Parte2* [Jupyter Notebook]. Google Colaboratory.
[\[https://colab.research.google.com/drive/1tuiv7XMz0iJ96lt8YF_SdtmOwO4M14sA?usp=sharing\]](https://colab.research.google.com/drive/1tuiv7XMz0iJ96lt8YF_SdtmOwO4M14sA?usp=sharing)
- Leite, J. (2026). *NB1-Parte3* [Jupyter Notebook]. Google Colaboratory.
[\[https://colab.research.google.com/drive/11Q2sVNeO6RaVJV5ZyZMP2wHW5Hpg-HTJ?usp=sharing\]](https://colab.research.google.com/drive/11Q2sVNeO6RaVJV5ZyZMP2wHW5Hpg-HTJ?usp=sharing)
- Leite, J. (2026). *NB2-Parte1* [Jupyter Notebook]. Google Colaboratory.
[\[https://colab.research.google.com/drive/1pkGuIn-xPAPpguRbOohGLtWJ19vLJdig?usp=sharing\]](https://colab.research.google.com/drive/1pkGuIn-xPAPpguRbOohGLtWJ19vLJdig?usp=sharing)
- Leite, J. (2026). *NB2-Parte2* [Jupyter Notebook]. Google Colaboratory.
[\[https://colab.research.google.com/drive/1T3AeIG4zBXNLQw3_zVG45eD98TSCeWCO?usp=sharing\]](https://colab.research.google.com/drive/1T3AeIG4zBXNLQw3_zVG45eD98TSCeWCO?usp=sharing)
- Leite, J. (2026). *NB3* [Jupyter Notebook]. Google Colaboratory.
[\[https://colab.research.google.com/drive/10dPQh-lk73UlnjvVw1av9SxGiAd8WHQR?usp=drive_link\]](https://colab.research.google.com/drive/10dPQh-lk73UlnjvVw1av9SxGiAd8WHQR?usp=drive_link)
- Leite, J. (2026). *NB4-Parte1* [Jupyter Notebook]. Google Colaboratory.
[\[https://colab.research.google.com/drive/1goCmb42Se9yi4x3UC1etP8bC9XFW3rYh?usp=sharing\]](https://colab.research.google.com/drive/1goCmb42Se9yi4x3UC1etP8bC9XFW3rYh?usp=sharing)
- Leite, J. (2026). *NB4-Parte2* [Jupyter Notebook]. Google Colaboratory.
[\[https://colab.research.google.com/drive/1EESEUvDN_K0cz6f5caAWXKuk1KvAmtR0?usp=sharing\]](https://colab.research.google.com/drive/1EESEUvDN_K0cz6f5caAWXKuk1KvAmtR0?usp=sharing)